

Классификация временных рядов динамических систем


Кирилл Сёмкин

Московский физико-технический институт
Кафедра интеллектуальных систем

Научный руководитель: д.ф.-м.н. В. В. Стрижов
2026

Задача классификации временных рядов

- *Многомерный временной ряд* — последовательность случайных векторов произвольной длины n $\mathbf{x}(t_i) = \{\mathbf{x}_{t_1}, \dots, \mathbf{x}_{t_n}\}$, $\mathbf{x}_{t_i} \in \mathbb{R}^d$, в моменты $t_1, \dots, t_n$.
- Каждому ряду соответствует метка класса (случайная величина) $y \in 1 \dots K$.
- *Классификатор* — отображение $\delta(\mathbf{x}(t_i))$, относящее ряд к классу.



Временные ряды трёх разных классов (IMU-сенсор)

Модель временных рядов — динамическая система

Классу j соответствует векторное поле $f_j \in \mathcal{F}(M)$. Ряд — зашумлённая фазовая траектория ОДУ

$$\begin{cases} \frac{d}{dt}\bar{\mathbf{x}}(t) = f_j(\bar{\mathbf{x}}), \\ \bar{\mathbf{x}}(0) = \bar{\mathbf{x}}_0, \end{cases} \quad \mathbf{x}(t_i) = \bar{\mathbf{x}}(t_i) + \epsilon(t_i), \quad (1)$$

где шум ϵ_{t_i} — i.i.d. случайные векторы:

$$\mathbb{E}[\epsilon_{t_i}] = 0, \quad \text{Cov}(\epsilon_{t_i}) = R, \quad \|R\|_2 \leq \sigma^2 < \infty.$$

Более общая модель — СДУ, фазовая траектория которой случайна:

$$\begin{cases} d\bar{\mathbf{x}}(t) = f_j(\bar{\mathbf{x}})dt + G_j dW(t), \\ \bar{\mathbf{x}}(0) = \bar{\mathbf{x}}_0, \end{cases} \quad (2)$$


где $W(t)$ — m -мерное броуновское движение, G_j — матрица диффузии класса.

Решение задачи Коши (IVP) обозначаем $\bar{\mathbf{x}}(t | \bar{\mathbf{x}}_0, f_j)$.

Восстановление фазовых траекторий по временным рядам

Пусть наблюдается не сама траектория, а её образ $x(t_i) = \alpha(\bar{x}(t_i)) + \epsilon(t_i)$, где $\alpha : M \rightarrow \mathbb{R}^d$, $\dim M = k$. Восстановление $\bar{x}(t_i)$ — через диффеоморфизм многообразий:

- **Теорема Уитни:** наблюдается $2k + 1$ рядов и α — типичное вложение $\Rightarrow$ наблюдения уже являются диффеоморфной траекторией
- **Теорема Такенса:** достаточно *одного* скалярного ряда — вложение строится из векторов задержек $(x(t_i), x(t_{i-1}), \dots, x(t_{i-m}))$, $m > 2k$.



Точка траектории $\bar{x}(t_i)$ собирается из лаговых значений ряда. Далее не различаем восстановленные и исходные траектории.

Метрический классификатор и его асимптотическая оптимальность

Введём метрику $\rho_n(\mathbf{x}(t_i), \mathbf{z}(t_i)) = \sum_{i=1}^n \|\mathbf{x}_{t_i} - \mathbf{z}_{t_i}\|_2^2$ и определим классификатор

$$\delta(\mathbf{x}(t_i)) = \arg \min_{j \in 1 \dots K} \rho_n(\mathbf{x}(t_i), \bar{\mathbf{x}}(t_i | \bar{\mathbf{x}}_0, f_j)).$$

Теорема (Сёмкин, 2026)

Пусть $\bar{\mathbf{x}}_0$ известна точно, шум удовлетворяет условиям модели и траектории классов расходятся:

$$\rho_\infty(\bar{\mathbf{x}}(t_i | \bar{\mathbf{x}}_0, f_j), \bar{\mathbf{x}}(t_i | \bar{\mathbf{x}}_0, f_p)) = +\infty \quad \forall j \neq p.$$


Тогда вероятность ошибки классификации стремится к нулю:

$$\mathbb{P}(\delta(\mathbf{x}(t_i)) \neq y) \rightarrow 0, \quad n \rightarrow \infty.$$


Доказательство — через неравенство Чебышёва и union bound; порядок сходимости $\mathcal{O}(\sigma^2/\rho_n)$.

Погрешности поля и ОДУ-солвера могут ухудшать качество классификации

$\|f - \tilde{f}\| \leq 0.1$, но траектории расходятся: центр против устойчивого фокуса



Жёсткая система: метод Эйлера с шагом $\tau = 0.05$ неустойчив, RK23 — точен




Кроме того, начальная точка случайна, $\bar{x}_0 \sim F(\cdot) \Rightarrow$ точное IVP $\bar{x}(t_i | \bar{x}_0, f_j)$ в классификаторе недостижимо на практике.

Сглаживание: условное матожидание вместо точного решения

Разобьём динамику на отрезки $[t_i, t_{i+1})$ и аппроксимируем $\bar{\mathbf{x}}(t_i | \bar{\mathbf{x}}_0, f_j)$ солвером:

$$\begin{cases} \bar{\mathbf{x}}_{t_{i+1}} = \text{ODESolve}(t_{i+1} - t_i | \bar{\mathbf{x}}_{t_i}, f), \\ \mathbf{x}_{t_i} = \bar{\mathbf{x}}_{t_i} + \epsilon_{t_i}, \\ \bar{\mathbf{x}}_0 \sim F(\cdot). \end{cases} \quad (3)$$



ОДУ $f(x) = -18x$: UKF точнее солверов с вероятностью 0.92 по оценке Монте-Карло

Наилучшее L_2 -приближение IVP по имеющимся данным — условное матожидание $\mathbb{E}[\bar{\mathbf{x}}(t_i) | \bar{\mathbf{x}}_0, \mathbf{x}(t_i), f]$. Его нахождение в условиях (3) — задача сглаживания. Новый классификатор:


$$\delta(\mathbf{x}(t_i)) = \arg \min_{j \in 1 \dots K} \rho_n(\mathbf{x}(t_i), \mathbb{E}[\bar{\mathbf{x}}(t_i) | \bar{\mathbf{x}}_0, \mathbf{x}(t_i), f_j]).$$

Для СДУ меняется только модель сглаживания

На малых отрезках диффузия аппроксимируется гауссовским шагом $G dW(t) \approx \xi_{t_{i+1}} \sim \mathcal{N}(0, (t_{i+1} - t_i) GG^T)$:

$$\begin{cases} \bar{\mathbf{x}}_{t_{i+1}} = \text{ODESolve}(t_{i+1} - t_i \mid \bar{\mathbf{x}}_{t_i}, f) + \xi_{t_{i+1}}, \\ \mathbf{x}_{t_i} = \bar{\mathbf{x}}_{t_i} + \epsilon_{t_i}, \\ \bar{\mathbf{x}}_0 \sim F(\cdot). \end{cases}$$

Это более общая задача сглаживания, решается только численно в общем виде (Extended/Unscented Kalman filter, particle filters, etc.).



СДУ $dx = x dt + dW(t)$: метод Эйлера расходится, UKF учитывает dW и точнее всех с вероятностью 0.97 по оценке Монте-Карло

Теоретическое обоснование аппроксимации полей методом NeuralODE через GMM

Из модели наблюдений следует моментное условие

$$\mathbb{E}[\mathbf{x}_{t_i} - \text{ODESolve}(t_i \mid \bar{\mathbf{x}}_0, f)] = 0, \quad i \in 1 \dots n.$$

Обобщённый метод моментов (GMM): ищем поле в параметрическом классе $\mathcal{S}_\Theta$, минимизируя по коротким батчам временных рядов B_j (NODE, градиентная оптимизация):

$$\sum_{j=1}^N \sum_{\bar{\mathbf{x}}_0, \mathbf{x}_{t_i} \in B_j} \|\mathbf{x}_{t_i} - \text{ODESolve}(t_i \mid \bar{\mathbf{x}}_0, f)\|_2^2 \rightarrow \min_{f \in \mathcal{S}_\Theta}.$$

Гарантия состоятельности

При выполнении технических условиях GMM на Θ имеем

$$f_{\hat{\Theta}} \xrightarrow{\mathbb{P}} f, \quad n \rightarrow \infty.$$

Короткие батчи ограничивают накопление ошибки ODEsolve. Для СДУ-динамики существуют аналоги NeuralODE.

Постановка вычислительных экспериментов

Цели

- 1 Эмпирически оценить качество классификации метрического классификатора на синтетических и реальных данных.
- 2 Сравнить с другими методами, использующие динамические системы: RNN и k -NN классификатор с dynamic time warping (DTW) метрикой.

Датасеты

- 1 Сэмплирование из трёх различных линейных ОДУ вида $f(\bar{x}) = A\bar{x}$
- 2 MotionSense — показания акселерометра и гироскопа для разных типов движений человека


Во всех экспериментах для вычисления $\mathbb{E}[\bar{x}(t_i) \mid \bar{x}_0, x(t_i), f]$ использовался UKF фильтр + RTS сглаживание.

Линейные ОДУ с общим типом динамики

Три системы с общим спектром Λ и разными базисами U (затухающие колебания + экспоненциальное затухание):

$$f(\bar{\mathbf{x}}) = U \begin{pmatrix} -\gamma_1 & w & 0 \\ -w & -\gamma_1 & 0 \\ 0 & 0 & -\gamma_2 \end{pmatrix} U^T \bar{\mathbf{x}}.$$

Длина ряда $n = 100$, уровень шума $\sigma = 2$.



Метод	Accuracy
k -NN + DTW	0.67
LSTM	0.27
UKF+RTS	0.86

LSTM не различает системы из-за сильного шума и общего Λ ; DTW субоптимален по метрике и использованию f_j .

MotionSense: движение человека как механическая система

Постановка: IMU-сигналы 50 Гц (угловая скорость + ускорение, $d = 6$), 6 субъектов, 6 активностей-классов: ходьба, бег, лестница вверх/вниз, статичное положение стоя и сидя. Поля f_j неизвестны — учим из данных.

Мотивация ОДУ: человек — система твёрдых тел, движение описывается уравнениями Лагранжа вида (1). Активные движения — предельные циклы, статичные движения — устойчивые равновесия. Поэтому ищем поле в виде $f(\bar{x}) = A\bar{x} + NN(\bar{x})$, где $A\bar{x}$ задаёт тип динамики, NN учитывает нелинейные детали движений.


Гипотеза индивидуальности: движения человека имеют множество особенностей $\Rightarrow$ каждый субъект имеет уникальное поле f_{subj_j} для каждого движения. Нулевая гипотеза: все f_{subj_j} одинаковы $\Rightarrow$ классификатор субъектов:

$$\delta(\mathbf{x}(t_i)) = \arg \min_{j \in 1 \dots \text{num subjects}} \rho_n(\mathbf{x}(t_i), \mathbb{E}[\bar{\mathbf{x}}(t_i) \mid \bar{\mathbf{x}}_0, \mathbf{x}(t_i), f_{\text{subj}_j}])$$


случен, т.е. его accuracy = 0.5.

Сглаженные траектории разделяют активности


Rotation rate




Acceleration



Rotation rate



Acceleration



Сверху: бег, сглаживание полями f_{jog} и f_{wlk} . Снизу: лестница вверх, поля f_{ups} и f_{sit} . «Своё» поле следует за рядом точнее чужого.

Классификация активностей

Активность	Accuracy
jog	0.84
walk	0.84
upstairs	0.72
downstairs	0.70
stand	0.75
sit	0.74
vce	0.765

Тест индивидуальности

Активность	p-value	Accuracy
jog	0.03	0.84
walk	0.01	1.00
upstairs	0.35	0.68
downstairs	0.34	0.71
stand	0.41	0.65
sit	0.89	0.34

Общая точность 0.765 в целом подтверждает ОДУ-модель. H_0 отвергнута для бега и ходьбы — наиболее сложных и динамичных движений. Для статичных поз индивидуальности не обнаружена, как и в ходьбе по лестнице.

- 1 Метод классификации временных рядов в модели динамических систем ОДУ/СДУ с учётом случайного шума.
- 2 Теорема об асимптотической оптимальности классификатора при известных полях и начальной точке; обоснование перехода к задаче сглаживания при нарушении этих условий.
- 3 Процедура состоятельного обучения векторных полей по данным (NODE + GMM).
- 4 Эмпирическая валидация на синтетических линейных системах и на данных MotionSense (accuracy 0.765). Формализация гипотезы индивидуальности движений и её проверка.