

Классификация временных рядов в пространстве модели с подходом NeuralODE

Сёмкин Кирилл

Московский физико-технический институт
Кафедра интеллектуальных систем

Научный руководитель: д.ф.-м.н. Стрижов Вадим Викторович
2025

Проблематика работы

Проблема

Необходим метод классификации временных рядов, порождаемых скрытыми динамическими системами. Классификация без учёта порождения данных может быть неустойчивой и некорректной.

Цель

Ввести вероятностную постановку порождения временных рядов в связке с моделью *ОДУ*. Решить проблему ненаблюдаемости порождающих динамических систем. Сформулировать формальную задачу классификации и предложить способы решения.

Решение

Использовать *NeuralODE* для аппроксимации динамических систем. Параметры системы могут быть фиксированными или порождаться *априорным* распределением. Классификацию осуществлять с помощью *байесовского тестирования гипотез* или строить классификатор в пространстве параметров дин. системы.


Постановка задачи

Задана обучающая и тестовая выборка временных рядов для каждого класса. Количество классов K .

Пусть для каждого класса существует динамическая система \mathbf{f}_i , порождающая траектории $\mathbf{z}(t)$ что

$$\begin{cases} \frac{d\mathbf{z}}{dt}(t) = \mathbf{f}_i(\mathbf{z}(t)), \\ \mathbf{z}(0) = \mathbf{0}. \end{cases}$$

Пусть существует функция наблюдений $\phi: \phi(\mathbf{z}(t)) = x(t)$.



Восстановление и параметризация дин. системы

Наложив некоторые условия регулярности на \mathbf{f}_i и ϕ , с помощью теоремы Такенса можем получить *вложение* исходных дин. систем в \mathbb{R}^m . Фазовыми траекториями будут *вектора задержки* $\overleftarrow{\mathbf{x}}_t$

$$\mathbf{z}(t) = \overleftarrow{\mathbf{x}}_t := \begin{pmatrix} x(t-L+1) \\ \vdots \\ x(t-1) \\ x(t) \end{pmatrix} \in \mathbb{R}^m.$$

Предположим, что векторные поля \mathbf{f}_i лежат в известном параметрическом классе, т.е. $\mathbf{f}_i = \mathbf{f}_{\Theta_i}$. Наконец наложим на траектории независимый шум с нулевым средним и ограниченной дисперсией

$$\begin{aligned} \mathbf{z}(t) &\rightarrow \mathbf{z}(t) + \epsilon, \\ \text{s.t. } \mathbb{E}[\epsilon] &= 0, \mathbb{D}[\epsilon] < +\infty. \end{aligned}$$

Полная модель порождения данных

Предлагаются три типа связи параметров Θ_i с дин. системами \mathbf{f}_i в рамках класса:

- 1 Дин. система класса имеет фиксированные параметры $\Theta_i = \text{const}$.
- 2 Класс имеет *априорное* распределение на параметры $\Theta_i \sim p_i(\Theta)$ (генеративная модель).

Добавив априорное распределение на классы $C \sim \text{Cat}(C)$, мы полностью определим вероятностную модель задачи.

- 3 Каждый параметр Θ задаёт распределение на класс $C \sim p(C|\Theta)$ (дискриминативная модель).





Рис.: Графические модели для 2 и 3 типов связи

Алгоритмы классификации временных рядов

Для каждого типа связи:

- 1 На обучающей выборке получить ML оценки параметров класса $\hat{\Theta}_i$. Для тестовой траектории воспользоваться *байесовским решающим правилом*:

$$C_{\text{test}} = \arg \max_{C_i} p(C_i) p(\mathbf{z}_{\text{test}}(t) | \hat{\Theta}_i)$$

- 2 Байесовский вывод





$$p(C = C_i | \mathbf{z}_{\text{test}}(t), \mathbf{z}_{\text{train}}(t)) = \int p(C = C_i | \Theta, \mathbf{z}_{\text{test}}(t)) p_i(\Theta | \mathbf{z}_{\text{train}}(t)) d\Theta$$

- 3 По каждой обучающей траектории получить ML оценку порождающей дин.системы $\hat{\Theta}$. Далее, на полученных оценках обучить классификатор в пространстве параметров $p(C | \Theta)$. Для тестовой траектории снова получаем оценку $\hat{\Theta}_{\text{test}}$, пользуемся классификатором:

$$C_{\text{test}} = \arg \max_{C_i} p(C_i | \hat{\Theta}_{\text{test}})$$

Фазовые траектории

Временные ряды активности "upstairs" и восстановленные фазовые траектории.



Классификация в пространстве параметров

Классы активности "jog" и "stand". Для каждой траектории обучалась линейная модель. В пространстве параметров построен kNN-классификатор. Приведены метрики качества для каждого класса (тестовая выборка) и визуализация t-SNE обученных моделей.

Label	Accuracy
jog	0.4
std	0.7






Рис.: t-SNE на параметрах обученных моделей. Perplexity = 15.

Байесовское решающее правило

Классы активности "jog" и "upstairs" с равномерным априорным распределением. Траектории поделены на train/test. NN-модели обучены на train. Тестовая траектория классифицируется по наибольшему правдоподобию у обученной модели. Приведены метрики качества для каждого класса (тестовая выборка), примеры аппроксимации реальной траектории обученными моделями.

Label	Accuracy
jog	0.68
ups	0.32



Выносятся на защиту

- ❶ Поставлена задача классификации временных рядов, порождённых скрытыми дин. системами
- ❷ Предложены три вероятностные модели порождения фазовых траекторий
- ❸ Для каждой модели предложен алгоритм классификации новых траекторий
- ❹ Поставлены вычислительные эксперименты по восстановлению параметров дин. систем и классификации

В ближайшее время будут проводиться эксперименты на данных гироскопа, где должно получиться более высокое качество классификации. Будет оформлена теор. оценка на точность классификации в связи с численной ошибкой ode-солвера. Работа оформляется для будущей публикации.